

contract-review-openclaw 技术路线

形式化审核流水线 范式合同对照 skill 嵌入 双门槛范本匹配器

liangch97

2026-05-07 v1.1

Abstract

本文档描述 `contract-review-openclaw-portable` 的技术路线，涵盖从合同输入到行政 PDF 输出的全流程；说明本次（v1.1）把范式合同对照能力拆为独立 OpenClaw skill 的设计动机与具体方案；给出范本匹配器从「单一形状相似度」升级为「形状 + 锚点」双门槛后的判定逻辑、阈值取值和回归验证结果。文末附上后续迭代规划。

Contents

1	背景与目标	2
2	整体架构	2
2.1	从一句话请求到行政 PDF	2
2.2	两个 skill 的分工	2
3	核心流水线	3
3.1	合同读取（ <code>contract_loader.py</code> ）	3
3.2	字段抽取（ <code>contract_extractor.py</code> ）	4
3.3	规则引擎（ <code>contract_rule_checker.py</code> ）	4
3.4	报告写出（ <code>contract_report_writer.py</code> ）	4
4	范本匹配器：从单门槛到双门槛	4
4.1	问题	4
4.2	双门槛设计	5
4.3	使用说明剥离（ <code>_strip_preamble</code> ）	5
4.4	决策结果与回归验证	5
5	Skill 拆分细节	6
5.1	<code>contract-formal-review-flow</code> （v1.1 精简版）	6
5.2	<code>contract-template-compliance</code> （v1.1 新建）	6
5.3	<code>template_match</code> 数据契约	7

6 部署与运维	7
6.1 安装	7
6.2 回归	8
6.3 回滚	8
7 后续迭代规划	8

1. 背景与目标

中山大学横向科研合同的形式化审核长期存在两类问题：

1. **形式化检查的覆盖度**：行政老师手工核对甲方信息、关键条款、知识产权归属、保密期限等，工作量大且容易疏漏。
2. **学校范本符合性**：中山大学发布了多份合同范本（技术开发委托、技术服务、技术咨询、专利技术转让、共同申请专利等），实际签订的合同与范本的偏离程度需要逐条比对。

`contract-review-openclaw-portable` 是面向 OpenClaw 平台的本地包，目标是让行政老师只在 IM 中发一句话 + 一个合同附件就拿到一份可直接转发的 行政版 PDF 报告，包含：

- 形式化审核结论（基本可审 / 建议修改 / 存在重大问题）。
- 关键问题清单与所对应合同条款 / 证据。
- 甲方企业核验结果（企查查 / 人工材料 / 未完成核验）。
- 知识产权归属与背景知识产权使用安排。
- 学校范本对照：是否基于学校范本，偏离了哪些条款。

2. 整体架构

2.1 从一句话请求到行政 PDF

图 1 给出端到端流水线。所有模块均位于本地 OpenClaw / WSL，无外部 LLM 调用，企查查访问受用户控制（扫码登录或本机会话复用）。

2.2 两个 skill 的分工

设计原则：每个 OpenClaw skill 单一职责、 ≤ 5 KB description；当一个 skill 的 `SKILL.md` 体量超过 15 KB 或 covering 5+ 异构工作流时，模型 attention 会被稀释、出现遗忘和混淆。本项目在 v1.1 迭代前正是因为把范本对照说明塞进主 skill，导致 `SKILL.md` 涨到 22 KB / 277 行，并发触发了「忘记 IM 模式回复结构」「忘记调用 `template-match`」等 skill 把握能力下降的现象。




Figure 1: 端到端流水线：两个并列 skill、一条管线、一份 PDF。

Skill	规模	职责
contract-formal-review-flow	1.4 KB / 214 行	形式化审核默认入口；执行规则、IM 模式、最终回复结构、知识产权摘要规则；不重述范本对照逻辑。
contract-template-compliance	7.2 KB / 99 行	范式合同对照专家：读取 <code>template_match</code> 字段并产出范本符合性结论；不独立运行任何脚本。

3. 核心流水线

3.1 合同读取 (contract_loader.py)

支持 .docx / .pdf / .txt，优先 .docx。 .docx 路径会读取：

- 正文段落 paragraphs
- 表格内容（含合并单元格按 | 拼接）
- Word 批注 word/comments.xml
- 高亮样式 w:highlight

输出 ordered_blocks（按文档顺序的段落 / 表格混合块）+ full_text。

3.2 字段抽取 (contract_extractor.py)

v1.1 在抽取层做了三件事：

1. 放宽标题正则。原 `HEADING_RE` 只匹配 第 X 条 / 阿拉伯数字 / 附件；新增对 一、 / (一) / 第一部分等编号的支持，覆盖 SYSU 范本的「使用说明」编号。
2. 党事方角色别名。原代码只识别 甲方 / 乙方；范本里大量使用 委托方 / 受托方 / 转让方 / 受让方 / 需求方 / 服务方 / 合作方 / 供方，因此引入 `_PARTY_ROLE_ALIASES` 把它们映射到 甲 / 乙 抽取槽位。
3. 接入范本匹配器。`_detect_template_match_safe` 包装异常并返回 `{matched: False, error: ...}`，把 `template_match` 写入 `extracted`。

3.3 规则引擎 (contract_rule_checker.py)

规则文件 `references/rules/horizontal_contract_formal_rules.yaml`，按严重程度分三级：

- `enforce`：自动可判定的硬性风险（如金额未填、知识产权归属缺失）。
- `review`：需要人工确认的事项（如保密期限是否合规）。
- `not_checked`：仅作参考，不计入风险数。

3.4 报告写出 (contract_report_writer.py)

输出三件套：`contract_review.md`（行政摘要）、`contract_findings_<hash>.json`（结构化结果，含 `template_match`、`summary_stats`、`findings`）、合同形式化审核总表.xlsx。

经 `full_qcc_review.py` 触发时，额外渲染并通过飞书推送 合同审核报告 _ 行政版.pdf（即行政老师拿到的最终交付物）。

4. 范本匹配器：从单门槛到双门槛

4.1 问题

v1.0 的 `template_matcher.py` 用 `difflib.SequenceMatcher` 直接对「合同正文 vs 范本正文（去波动 token 后）」算相似度，超过 $\theta_{\text{shape}} = 0.40$ 即判定为「基于学校范本」。

失败案例（反例）：行业起草的技术服务合同，乙方为中山大学。该合同与 中山大学技术服务合同.docx 共享大量套话（甲乙方、知识产权、保密、违约责任、争议解决），但其余条款完全是行业自己的。结果：

- 实测相似度 ≈ 0.56 ，被误判为「基于学校范本」。
- 行政 PDF 的「三、学校范本对照」一节里凭空冒出 28 个 `removed`、32 个 `added`（来自范本前置「使用说明」段被切成条款的噪声）。

4.2 双门槛设计

新版判定要求形状信号与内容信号同时通过：

$$\text{matched} = (s_{\text{best}} \geq \theta_{\text{shape}}) \wedge (\#\text{anchor}_{\text{contract}} \geq k_{\text{anchor}}) \quad (1)$$

其中：

- $s_{\text{best}} = \max_T \text{Ratio}(\sigma(C), \sigma(T))$, C 是合同文本、 T 是范本文本、 σ 是 `_strip_volatile` (清掉日期 / 金额 / 占位符等易变 token)。
- $\theta_{\text{shape}} = 0.65$ (v1.0 是 0.40; v1.1 抬高 25 个百分点, 在反例 0.56 与正例 1.00 之间稳定区分)。
- `anchor` 集为学校范本独有的短语集合 (见表 2), $k_{\text{anchor}} = 1$ 。

Table 2: SYSU 范本独有锚点短语 (v1.1)

保留 (独有)	已剔除 (中性 / 误导)
【科学研究院】	中山大学
【科研管理部门】	中大
学校合同管理信息系统	示范文本
合同管理信息系统	
中山大学 · 深圳 / 中山大学 · 深圳 / 中山大学 深圳	
本合同由【科学研究院】	
本合同由【科研管理部门】	

为何剔除 中山大学 / 示范文本 / 中大? 中大经常作为乙方出现在行业自拟合同中 (这只能说明合同的乙方是中大, 并不意味着合同采用了学校范本); 示范文本还会出现在国家科技部范本里。这三个短语没有判别力, 必须移出锚点集合。

4.3 使用说明剥离 (`_strip_preamble`)

SYSU 范本 .docx 起始处有一段「使用说明」, 编号为一、二、三、...七、, 解释如何填写范本。这些不是真正的合同条款, 会在逐条 diff 时产生大量 `removed` / `added` 噪声。

实现策略: 当文本中存在第 N 条时, 丢弃第一处第 N 条之前的所有行; 否则保留原文 (避免误删纯条目式合同)。

4.4 决策结果与回归验证

实测两个样例 (通过 `run_contract_review.py` 全流水线):

案例	matched	相似度	anchor 命中	结论
反例 PCDW_neg.docx (行业自拟、乙方为大)	False	0.41	0	non_template_contract: similarity_0.41<0.65 and anchors_0<1
正例 zhuanli_pos.docx (基于专利转让范本)	True	0.95	5	匹配《中山大学专利技术转让合同.docx》；未改动 38 / 修改 9 / 改写 5 / 新增 2 / 删除 7

5. Skill 拆分细节

5.1 contract-formal-review-flow (v1.1 精简版)

主入口 skill。保留：

- 强制执行规则（每次必须重跑脚本、不输出文本摘要、单条飞书回复等）。
- 禁用响应表（含「未收到附件」「请告诉我您的称呼」等典型错误）。
- IM 模式默认命令 `python3 /root/full_qcc_review.py "<path>"`。
- 最终回复 7 节结构（含「学校范本对照」一节，但只占一句话）。
- 知识产权摘要规则。

外移至 `references/handoff/qcc_and_arkclaw.md`：QCC 二维码登录 demo、ArkClaw 连接器输出清单、本地浏览器会话复用细节。

YAML description: 双引号字符串，规避：触发的 mapping 歧义。

5.2 contract-template-compliance (v1.1 新建)

触发词：范本 / 范式 / 示范文本 / 学校范本 / 中大范本 / 范本对照 / 模板对照 / 条款偏离 / template compliance / clause deviation。

决策规则（必须三选一）：

1. `matched = False`：「本合同不是基于中山大学合同范本起草，按通用横向合同审核要点审查」。
2. `matched = True ^ modified_count = 0`：「与学校范本《<name>》一致，无条款偏离」。
3. `matched = True ^ modified_count > 0`：给出范本名 + 偏离统计 + 重点偏离条款表（按 `diff_ratio` 升序最多 6 条）。

禁止行为：

- 在 `matched=False` 时列「范本对照表」。

- 仅凭乙方是「中山大学」就声称采用了学校范本。
- 把 `template_match.reason` 字段（含英文）原样贴给老师。
- 直接显示英文 `status`（应映射为「未改动 / 有修改 / 重大改写 / 合同新增 / 范本中存在但合同未见」）。

5.3 `template_match` 数据契约

Listing 1: `template_match` 字段 (v1.1)

```
{
  "matched": true,
  "template_name": "中山大学专利技术转让合同.docx",
  "similarity": 0.947,
  "anchor_hits": 5,
  "anchor_min": 1,
  "match_threshold": 0.65,
  "templates_considered": [...],
  "reason": null,
  "clauses": [
    {
      "id": "第三条",
      "title": "...",
      "status": "modified",
      "diff_ratio": 0.72,
      "template_excerpt": "...",
      "contract_excerpt": "..."
    }
  ],
  "counts": {"unchanged": 38, "modified": 9, "rewritten": 5,
    "added": 2, "removed": 7},
  "modified_count": 23,
  "summary": "匹配范本: ... (相似度 95%, 命中范本特征 5 项); ..."
}
```

6. 部署与运维

6.1 安装

```
# 1. 克隆仓库
git clone https://github.com/liangch97/verifyAgent.git
cd verifyAgent

# 2. Python 依赖
pip install -r requirements.txt

# 3. 安装两个 skill 到 ~/.openclaw/skills/
```

```
python install_into_openclaw.py
```

6.2 回归

```
# 范本匹配器单元
python3 _diag_template_match.py
python3 _diag_anchors.py
python3 _diag_clauses.py

# Skill 元数据 + 匹配器联合
python3 _smoketest_skills.py

# 端到端流水线
python3 _e2e_template.py
```

6.3 回滚

如需回滚到 v1.0 的整段 SKILL.md:

```
cp ~/.openclaw/skills/contract-formal-review-flow/SKILL.md.preTemplateSplit.bak \
    ~/.openclaw/skills/contract-formal-review-flow/SKILL.md
rm -rf ~/.openclaw/skills/contract-template-compliance
```

7. 后续迭代规划

1. **语义化范本匹配**: 在 `template_matcher.py` 中加入条款级 embedding (如 BGE-small-zh) 做「语义相似度」与现有形状相似度的融合, 进一步降低边缘案例 (相似度 0.55~0.65) 的误判风险。
2. **条款级建议生成**: 把 `clauses[].status=rewritten` 的条款交给规则引擎做二次审查, 生成针对性的修改建议。
3. **多范本组合**: 支持「主范本 + 附加条款范本」的组合识别 (如专利技术转让 + 共同申请专利的复合合同)。
4. **打分一致性测试**: 构造 30+ 条「微改写」/「重命名甲乙双方」/「调整条款顺序」的合成样本, 回归确保 `counts` 的稳定性。
5. **Skill 元数据校验**: 把 `install_into_openclaw.py` 加上 YAML 解析 + `description` 长度 / 触发词覆盖度的预检, 避免装入破损的 SKILL.md。

附录 A: 版本要点

- **v1.0 (2026-04)**: 单 skill; 范本匹配器单门槛 $\theta = 0.40$ 。

- **v1.1** (2026-05): 双 skill 拆分; 匹配器升级为形状 + 锚点双门槛; 外移 QCC / ArkClaw 长篇手册; 新增 CHANGELOG。